Практическая работа №3

Статистика и качество данных в Python

Цель: провести исследовательский анализ данных, поставить гипотезы и выявить основные статистики.

Содержание

Общее задание на работу..... 1
Варианты самостоятельной работы..... 2
Требования к проекту..... 3
Сложность выполнения..... 3
Формат выполнения задания..... 4

Общее задание на работу

1. Ознакомьтесь с набором данных mpg из библиотеки Seaborn.

(загрузка через df = sns.load_dataset('mpg'))

2. Посчитайте количество строк и столбцов.
3. Проведите разведочный анализ, то есть:

(a) для каждой числовой переменной вычислите:

- Долю пропусков
- Максимальное и минимальное значение
- Среднее значение
- Медиану
- Дисперсию
- Квантиль 0.1 и 0.9
- Квартиль 1 и 3

(b) для каждой категориальной переменной вычислите:

- Долю пропусков
- Количество уникальных значений
- Моду

4. Сформулируйте и проверьте минимум 2 статистические гипотезы. Выбор критериев для проверки гипотез требуется обосновать. Сделать выводы в терминах предметной области.

5. Закодируйте категориальные переменные, необходимые для анализа, если требуется. Методом OneHotEncoding или LabelEncoding.

6. Постройте таблицу корреляции признаков и целевого столбца. Обоснуйте, какой столбец является целевым, а какие признаками.

7. Загрузите данные вашего варианта самостоятельной работы. Проведите разведочный анализ.

Варианты самостоятельной работы

№	Вариант	Ссылка на kaggle
1	SQL Murder Mystery Database	https://www.kaggle.com/datasets/johnp47/sql-murder-mystery-database
2	SQLite Sakila Sample Database	https://www.kaggle.com/datasets/atanaskanev/sqlite-sakila-sample-database?select=SQLite3+Sakila+Sample+Database+ERD.png
3	Bike Store Relational Database | SQL	https://www.kaggle.com/datasets/dillonmyrick/bike-store-sample-database
4	Indian Premier League SQLite Database	https://www.kaggle.com/datasets/harsha547/ipldatabase
5	Housing - SQL Project	https://www.kaggle.com/datasets/bvanntruong/housing-sql-project
6	NBA Database	https://www.kaggle.com/datasets/wyattowalsh/basketball
7	Formula 1 Race Data (SQLite)	https://www.kaggle.com/datasets/davidcochran/formula-1-race-data-sqlite
8	League of Legends Ranked Matches	https://www.kaggle.com/datasets/paololol/league-of-legends-ranked-matches
9	Sample databases for the SQL Server	https://www.kaggle.com/datasets/emrahaydemr/sample-databases-for-the-sql-server-course
10	UEFA Champions League 2016-2022 Data	https://www.kaggle.com/datasets/cbxkgl/uefa-champions-league-2016-2022-data
11	Kensho Derived Wikimedia Dataset	https://www.kaggle.com/datasets/kenshoresearch/kensho-derived-wikimedia-data
12	SQL Murder Mystery Database	https://www.kaggle.com/datasets/johnp47/sql-murder-mystery-database

13	SQLite Sakila Sample Database	https://www.kaggle.com/datasets/atanaskanev/sqlite-sakila-sample-database?select=SQLite3+Sakila+Sample+Database+ERD.png
14	Bike Store Relational Database | SQL	https://www.kaggle.com/datasets/dillonmyrick/bike-store-sample-database
15	Indian Premier League SQLite Database	https://www.kaggle.com/datasets/harsha547/ipldatabase
16	Housing - SQL Project	https://www.kaggle.com/datasets/bvanntruong/housing-sql-project
17	NBA Database	https://www.kaggle.com/datasets/wyattowalsh/basketball
18	Formula 1 Race Data (SQLite)	https://www.kaggle.com/datasets/davidcochran/formula-1-race-data-sqlite
19	League of Legends Ranked Matches	https://www.kaggle.com/datasets/paololol/league-of-legends-ranked-matches
20	Sample databases for the SQL Server	https://www.kaggle.com/datasets/emrahaydemr/sample-databases-for-the-sql-server-course
21	UEFA Champions League 2016-2022 Data	https://www.kaggle.com/datasets/cbxkgl/uefa-champions-league-2016-2022-data
22	Kensho Derived Wikimedia Dataset	https://www.kaggle.com/datasets/kenshoresearch/kensho-derived-wikimedia-data
23	Housing - SQL Project	https://www.kaggle.com/datasets/bvanntruong/housing-sql-project

Требования к проекту

- Проект реализован локально или выгружен в colab или прикреплен в архиве к заданию в elearning
- Проект реализуется в файле *.ipynb
- Проект реализован на python с применением библиотеки pandas, seaborn.

Сложность выполнения

Сложность: Rare

- Загрузить данные

- Провести разведочный анализ
- Сформулирована и проверена 1 гипотеза
- Категориальные данные выявлены, но не обработаны

Сложность: Medium

- Загрузить данные
- Провести разведочный анализ
- Сформулирована и проверена 2 гипотезы
- Закодированы категориальные переменные, необходимые для анализа, если требуется. Методом OneHotEncoding или LabelEncoding. Есть обоснование метода кодирования

Сложность: Well-done

- Загрузить данные
- Провести разведочный анализ
- Сформулирована и проверена 2 гипотезы
- Закодированы категориальные переменные, необходимые для анализа, если требуется. Методом OneHotEncoding или LabelEncoding. Есть обоснование метода кодирования
- Построена таблица корреляции признаков и целевого столбца. Обосновано, какой столбец является целевым, а какие признаками.
- Загружены данные варианта самостоятельной работы (достаточно одной таблицы) и проведен по ним разведочный анализ

Формат выполнения задания

1. Желательна реализация в файлах .py.
2. Загрузить практику на github и указать версию python
3. README.md обязателен, как и requirements.txt